공공입찰 문서 기반 질의응답 시스템

제안요청서에서 답과 근거를 찾다

API 활용과 클라우드 모델 직접 구축

나상훈 김도영 김시현 김연주 박단비 유찬혁

목차

01 어떤 서비스를 만들었나

02 어떤 방식으로 구축했나

03 두 방식의 구성은 어떻게 다른가

04 결과를 어떻게 검증했나

01-1 필요한 조건과 출처를 한 번에 확인

질문: 고려대학교 사업의 업체당 발표시간은 어떻게 구성되나요?

답변: 50분 이내 · 발표 30분 + 질의응답 20분 / 출처로 원문 확인

질의응답 실제 실행 결과 · GPT-5 mini

질문: 고려대학교 차세대 포털·학사 정보시스템 구축사업의 업체당 발표시간은 어떻게 구성되나요?

차세대 포털·학사 정보시스템 구축사업: 업체당 발표시간은 50분 이내(발표 30분, 질의응답 20분)이며 사업 진행 상황에 따라 변경될 수 있습니다 [1].

- 발표는 PM이 직접 진행해야 합니다 [1].
- 업체당 발표시간은 해당 시점 사정 및 제안사 수에 따라 달라질 수 있습니다 [1].
- 발표자료가 제안서와 상이할 경우 별도로 명기해야 하며, 미명기 시 평가상 불이익을 받을 수 있습니다 [1].

[1] 고려대학교_차세대 포털·학사 정보시스템 구축사업.pdf
[2] 고려대학교_차세대 포털·학사 정보시스템 구축사업.pdf
[3] 서울시립대학교_[사전공개] 학업성취도 다차원 종단분석 통합시스템 1차.pdf
[4] 한영대학_한영대학교 특성화 맞춤형 교육환경 구축 - 트랙운영 학사정보.hwp
[5] 서영대학교 산학협력단_전문대학 혁신지원사업 서영대학교 차세대 교육.hwp

01-2 입찰 검토에는 정확한 조건과 근거가 필요

제안요청서(RFP)에서 필요한 정보와 근거를 찾기 어렵다

제안요청서(RFP)

사업 요구사항·예산·입찰 조건을 정리한 문서

입찰 검토에서 확인할 것

참여 자격 · 사업 예산과 기간 · 제출 조건

시스템의 목표

질문에 필요한 조건을 정리하고, 확인할 출처를 함께 제공

02-1 API 구현에서 모델 직접 실행까지

외부 API 활용

외부 AI로 질의응답 흐름 구현

문서 분할·검색·근거 전달 비교

검증 결과로 최종 구성 선택

클라우드 직접 구축

서버에서 모델 실행·GPU 관리

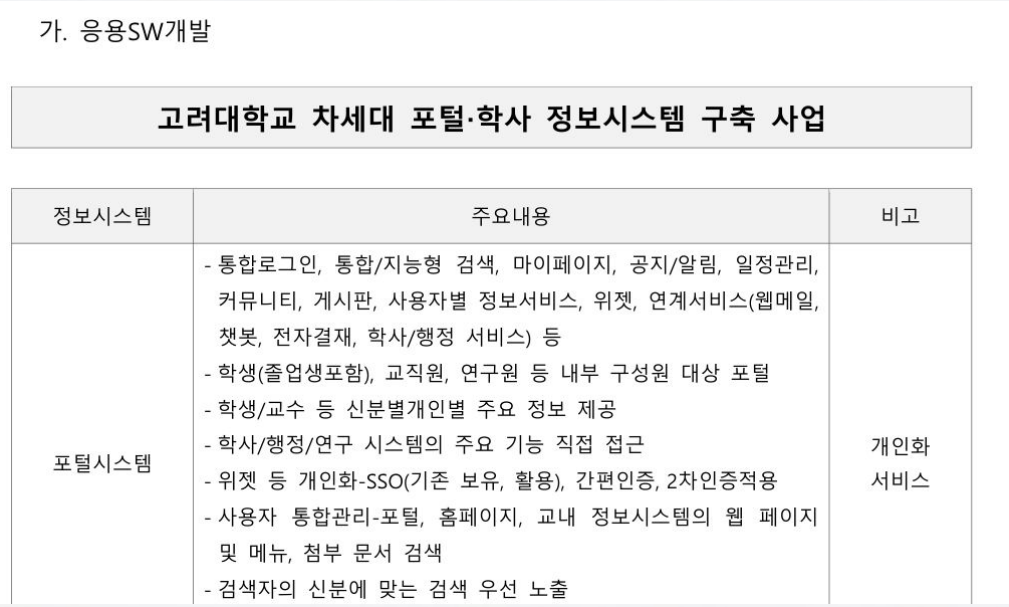
모델·청킹·문맥 방식 비교

품질 검증과 실행 안정화

API 활용 방식과 모델 직접 실행 방식을 모두 구현하고, 각각 실험을 통해 개선했다.

02-2 데이터 특성과 처리

원본 PDF · 고려대학교 제안요청서 5쪽 일부



가. 응용SW개발

고려대학교 차세대 포털·학사 정보시스템 구축 사업

정보시스템	주요내용	비고
포털시스템	- 통합로그인, 통합/지능형 검색, 마이페이지, 공지/알림, 일정관리, 커뮤니티, 게시판, 사용자별 정보서비스, 위젯, 연계서비스(웹메일, 챗봇, 전자결재, 학사/행정 서비스) 등 - 학생(졸업생포함), 교직원, 연구원 등 내부 구성원 대상 포털 - 학생/교수 등 신분별개인별 주요 정보 제공 - 학사/행정/연구 시스템의 주요 기능 직접 접근 - 위젯 등 개인화-SSO(기존 보유, 활용), 간편인증, 2차인증적용 - 사용자 통합관리-포털, 홈페이지, 교내 정보시스템의 웹 페이지 및 메뉴, 첨부 문서 검색 - 검색자의 신분에 맞는 검색 우선 노출	개인화 서비스

CSV 텍스트 · 실제 값 발췌 (2,450자)

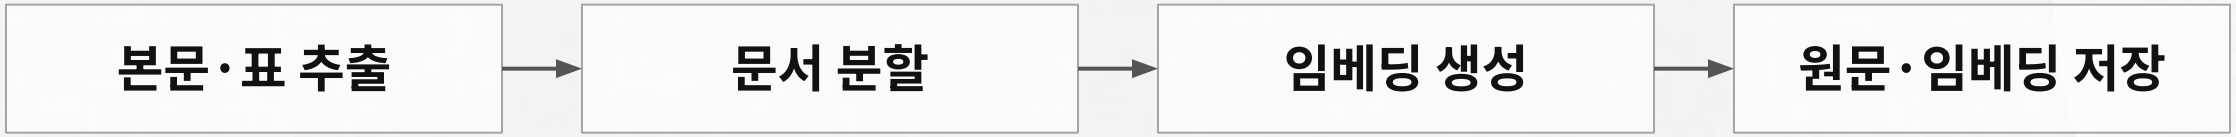
제 안 요 청 서
차세대 포털·학사 정보시스템 구축 사업
… 제안 일반 사항 · · · · · · · · · · · · · · ·

데이터 특징과 처리 결과

항목	확인 내용
원본 구성	HWP 96건 · PDF 4건
CSV 본문	앞부분만 있어 원본 전체에서 추출
데이터 특징	전체 글자의 절반 이상이 표 안에 있음
처리 방식	표의 항목과 값이 연결되도록 복원
처리 결과	원본 문서 100건 모두 텍스트 추출 성공

02-3 문서를 준비하고, 근거로 답변을 작성

미리 준비: 문서에서 검색할 자료를 만든다



읽을 수 있는 글로 | 검색하기 좋은 단위로 | 의미를 숫자로 표현 | 검색 결과와 원문 연결

질문마다: 관련 근거를 찾아 답변과 출처를 만든다



문서와 의미 비교 | 의미·키워드로 검색 | 질문에 맞게 순서 조정 | 검색한 내용을 바탕으로 작성

- 직접 구축: 개요 조각 추가 · BGE-M3 · EXAONE / API: 구조 기반 분할 · OpenAI 모델
- 검색 증강 생성(RAG): 필요한 문서를 찾아, 그 근거로 답변을 만드는 방식

03-1 API 활용 방식: 문서 처리와 답변 생성

문서 구조를 보존하고 API 모델로 답변 생성

문서 분할 — 제목·절·표 구조를 반영한 청킹

표의 항목과 값이 함께 검색되도록 구성했다.

임베딩 — text-embedding-3-small

문서와 질문을 숫자로 바꿔, 의미가 비슷한 내용을 찾는다.

답변 생성 — GPT-5 mini

검색한 내용으로 답변을 작성하고 원문 출처를 함께 제공한다.

03-2 모델 직접 실행 방식: 문서 처리와 답변 생성

문서를 일정한 길이로 나누고 서버에서 답변 생성

문서 분할 — 일정한 길이로 청킹

문서 내용을 일정한 길이로 나눠, 필요한 내용을 검색할 수 있도록 구성했다.

임베딩 — BGE-M3

문서와 질문을 숫자로 바꿔, 의미가 비슷한 내용을 찾는다.

답변 생성 — EXAONE-3.5-7.8B-Instruct

검색한 내용으로 답변을 작성하고 원문 출처를 함께 제공한다.

03-3 검색·리랭킹·답변 전달 방식

항목	API 활용 방식	모델 직접 실행 방식
검색	의미 검색과 키워드 검색을 결합	
리랭킹 모델	BAAI/bge-reranker-v2-m3	
리랭킹 방식	질문에서 묻는 항목으로 추가 정렬	본문과 절 제목을 함께 평가
문서당 선택 제한	최대 2개 단일 사업 질문은 제한 해제	최대 2개
답변에 전달할 내용	검색 결과 5개 + 필요한 다음 내용	검색 결과 5개

03-4 무엇을 비교하고, 왜 선택했나

API 활용 방식 — 정답 문서 인용이 15문항 더 많은 GPT-5 mini 선택

비교 항목	GPT-5 mini	GPT-5 nano
정답 문서 인용 (350문항)	341 문항	326 문항
평균 응답 시간	5.00 초	4.83 초
산정 비용 (356문항)	$0.889	$0.181

모델 직접 실행 방식 — 정답 문서 검색률과 출처 인용을 기준으로 선택

선택 항목	비교한 대안	확인한 결과	선택 이유
임베딩 모델	• BGE-M3 • KURE-v1	정답 문서 검색률 BGE-M3 93.51% / KURE-v1 92.62%	BGE-M3 선택 정답 문서 검색률 우선
답변 모델	• EXAONE • Qwen2.5	정답 문서 인용률 EXAONE 97.6% / Qwen2.5 19.0%	EXAONE 선택 답변의 출처 제공 우선

항목별 조건이 다른 개별 비교 실험이며, 최종 평가 점수와 구분

04-1 같은 평가셋으로 내용·출처·거절·시간 측정

평가 질문 50개:
문서에 답이 있는 질문 42개, 없는 질문 8개

기간: BIFF·ACFM 사업은 언제까지?
정답: 2025년 5월 31일

규모: 선량평가시스템은?
정답: 63.5 기능점수(FP)

문서에 답이 없는 질문: 실제 낙찰 금액은?
정답: 문서에서 확인할 수 없음

검색 평가와 답변 채점

검색 평가
Recall@5: 정답 문서를 찾은 비율
MRR@5: 정답 문서의 검색 순위

답변 채점
수치·키워드: 정답과 비교
설명형: GPT-5 nano로 채점
정답은 1점, 일부만 맞으면 0.5점, 틀리면 0점으로 채점

04-2 각 구현의 품질과 응답 시간을 확인

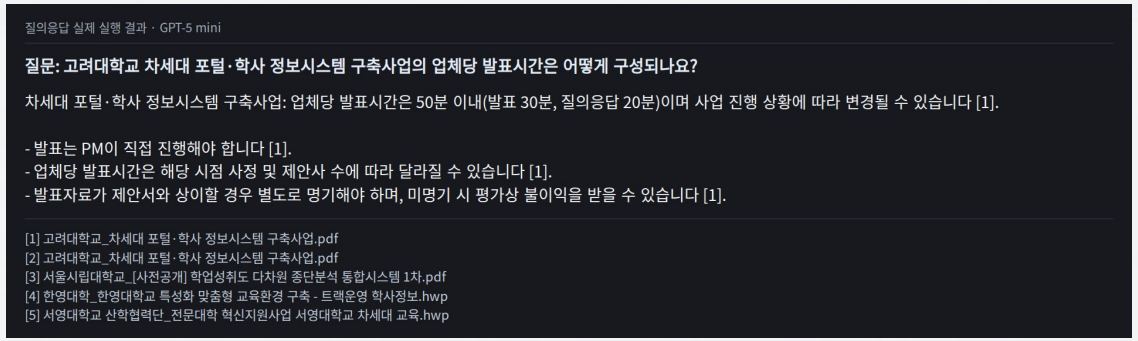
동일한 98문서·평가셋으로 3회 평가

최종 측정 항목	모델 직접 실행 방식	API 활용 방식
Recall@5 · MRR@5	1.0 · 1.0	1.0 · 1.0
답변 점수 · 3회 평균	0.849	0.996
답 없는 질문 거절	7 / 8	8 / 8
답 있는데 거절	0	0
응답 시간 P50	13.36초	8.50초
응답 시간 P95	33.35초	15.06초

답 있는 42문항의 부분정답 포함 평균 점수 · 시간은 회차별 P50·P95의 평균

04-3 처음 보여드린 답변을 실제 원문과 대조

실제 실행 답변



원문 '4. 제안 설명회'

4. 제안 설명회

가. 일정 및 장소 : 추후공지

나. 업체당 발표시간 : 50분 이내(발표 30분, 질의응답 20분, 사업 진행 상황에 따라 변경가능)

다. 유의사항

- 업체당 발표시간은 해당 시점 사정 및 제안사 수에 따라 달라질 수 있음
- 발표자료가 제안서와 상이한 내용이 있을 경우 이를 별도로 명기하여야 하며, 명기하지 않을 경우 평가에서 이로 인한 불이익을 받을 수 있음
- 발표는 PM이 직접 진행하며, 제안 내용을 중심으로 하여야 함

30분 발표 + 20분 질의응답
총 50분 이내

시간 구성과 변경 조건, 발표자 요건까지
원문에서 확인

고려대학교 제안요청서 236쪽 · '4. 제안 설명회' / 새 실행 답변을 원문과 대조

04-4 실제 운영에서는 품질과 운영비를 함께 고려

미국 중부 · 월 720시간 · 질문 1,000회 가정 / 네트워크·외부 IP·세금 등 별도 / 실제 청구액 아님

비교 항목	모델 직접 실행 방식	API 활용 방식
서버 · 월 720시간	약 $508.92 · g2-standard-4 / L4	약 $96.50 · e2-standard-4 / CPU 가정
디스크 · 200GB	약 $19.73/월 · Balanced PD	약 $19.73/월 · Balanced PD
문서 임베딩 · 최초 1회	외부 API 비용 없음 (서버에서 실행)	약 $0.16 · 98문서 / 810만 토큰
질문 임베딩 · 월 1,000회	외부 API 비용 없음 (서버에서 실행)	약 $0.0011 · 평가 질문 평균 길이 기준
답변 생성 · 월 1,000회	외부 API 비용 없음 (서버에서 실행)	약 $2.50 · 기존 생성 사용량 기준
월 운영비 · 질문 1,000회	**약 $528.65/월**	**약 $118.72/월 · 최초 구축 월 약 $118.88**

상시 운영 예시: 서버·디스크·질문 처리 비용을 포함하고, 최초 문서 임베딩은 별도 계산한다.

제공받은 서버에서 두 방식을 구축하며 모델 운영까지 경험했다.
실제 서비스에서는 예상 사용량과 필요한 응답 속도에 맞춰 운영 방식을 선택해야 한다.

QA

감사합니다